

Адаптивный выбор параметров распределения сэмплирования для Monte Carlo оценки сходимости оптимизационной поверхности

Еникеев Арнольд и Никита Киселёв

Аннотация

Исследование поведения функции потерь возле минимума является важной задачей для работы нейросетей и для поиска оптимального размера обучающей выборки. Распределенный подход к оценке сходимости поверхности функции потерь использует Monte Carlo сэмплирование из гауссовского распределения в окрестности минимума. Предыдущие исследования показали, что оценка сильно зависит от дисперсии сэмплирования. Целью исследования является разработка адаптивных методов выбора параметров распределения сэмплирования на основе свойств кривизны оптимизационной поверхности и провести сравнительный анализ различных стратегий выбора. В данной работе предлагается метод, использующий свойства матрицы Гессе для более точной оценки сходимости поверхности функции потерь. Различные стратегии выбора сравниваются на задаче классификации изображений. Развитие исследований в этом направлении позволит сделать распределенный подход более практичным и устойчивым. Результаты могут быть полезны для анализа оптимальной обучающей выборки в задаче обучения нейросетей.

1 Введение




Рис. 1: Критерий выбора параметра σ : точки сэмплирования должны попадать в шар характерного радиуса с центром в минимуме $\mathcal{L}(\mathbf{w}^*)$

В статистической теории машинного обучения [1] качество модели напрямую зависит от размера обучающей выборки. Для параметрических моделей функция потерь вычисляется по ограниченному набору данных, поэтому существует важная задача по определению

оптимального размера обучающей выборки. Для этого исследуется сходимость ландшафта функции потерь в зависимости от размера выборки. Когда геометрия ландшафта перестёт значительно меняться при добавлении нового элемента, можно делать выводы о достаточности размера обучающих данных.

В предыдущих исследованиях [2, 3] были предложены критерии оценки сходимости оптимизационной поверхности при увеличении размера выборки, использующие гауссовское сэмплирование в окрестности минимума $\mathcal{L}(\mathbf{w})$. В [Прочитывать статью, которая ещё не вышла] вводятся ещё два критерия, которые более эффективны с вычислительной точки зрения, а также доказывается их сходимость. Однако, для того, чтобы критерий корректно описывал сходимость ландшафта, необходимо, чтобы сэмплирование отражало свойства окрестности $\mathbf{w}^*$, в которой корректна аппроксимация Тейлора 2 порядка для дальнейших теоретических выводов.

Наша задача состоит в том, чтобы предложить метод выбора параметра σ , при котором сэмплирование будет отражать свойства области, в которой корректна аппроксимация Тейлора 2 порядка, проверить корректность предложенного метода выбора параметра и проверить предложенные в предыдущих исследованиях критерии для выведенного значения σ .

2 Связанные работы

Исследование зависимости ландшафта функции потерь от размера обучающей выборки. Анализ зависимости обучения параметрической модели от размера выборки является важной задачей в классической теории обучения [1]. В недавних исследованиях были предложены критерии оценки сходимости ландшафта функции потерь при увеличении объёма данных [3, 4], в частности, квадратичный критерий Δ_2 и абсолютный критерий Δ_1 , а также показана их сходимость. В [2] предложена идея делать гауссовское сэмплирование точек по Монте-Карло для оценки сходимости на практике. В статье [Прочитывать статью, которая ещё не вышла] предложены критерии Quadratic Monte-Carlo и Gaussian-moment quadratic estimator, которые более эффективны для вычислений, однако полагаются на то, что точки сэмплирования попадают в область корректности аппроксимации Тейлора 2 порядка. В нашей работе мы предлагаем адаптивный метод выбора параметра σ , при котором гарантируется выполнение квадратичной аппроксимации с заданной точностью и проводим вычислительный эксперимент с полученным σ для сходимости данных критериев. В отличие от предыдущих работ, мы получаем точное выражение для параметра σ и показываем его корректность, а не работаем в абстрактной области корректности аппроксимации Тейлора 2 порядка.

Ландшафт функции потерь и его локальная геометрия. Изучению локальной геометрии функции потерь посвящено значительное количество работ, предлагающих теоретический анализ и различные подходы к визуализации ландшафта [5, 6]. В частности, в них были описаны особенности кривизны ландшафта и спектральные свойства матрицы Гессе [7, 8, 9].

Предыдущие исследования показали, что на практике ландшафт функции потерь крайне анизотропен, то есть значительная часть спектра матрицы Гессе имеет околонулевые значения [10, 11]. В недавних исследованиях для практического изучения ландшафта функции потерь была предложена идея сэмплирования в подпространстве наибольшей кривизны, то есть подпространство d главных собственных векторов матрицы Гессе $\mathbf{H}$ [статья с идеей перехода в подпространство наибольшей кривизны и с доказательством оптимальности среди всех подпространства размера D]. В нашей работе мы развиваем данную идею и предлагаем метод выбора параметра σ для сэмплирования в данном подпространстве и показываем, что при таком выборе σ сэмплирование будет отражать локальные свойства минимума $\mathcal{L}(\mathbf{w})$.

Локальные свойства ландшафта в методах оптимизации. Также ряд работ был

посвящён изучению связи геометрии ландшафта функции потерь и структуры матрицы Гессе с работой методов стохастической оптимизации. Для функции потерь параметрических моделей разделяют flat (плоские) и sharp (острые) минимумы по кривизне поверхности в их окрестности [12]. В частности, согласно результатам исследований, в случае flat минимумов параметрическая модель обладает большей обобщающей способностью [13, 14, 15]. Было показано, что стохастические методы, такие как SGD, за счёт недетерминированных обновлений обычно приводят к решениям в более плоских минимумах. В недавних работах было изучено, как ведут себя траектории SGD на всём пространстве параметров и в подпространствах наибольшей кривизны [16, 17]. В методах оптимизации важно понимать, как устроена окрестность минимума и уметь исследовать структуру ландшафта в подпространствах собственных векторов матрицы Гессе, что тесно пересекается с нашей работой. В отличие от других исследований, в нашей работе мы также предлагаем численные оценки для характерного радиуса корректности аппроксимации Тейлора 2 порядка и показываем, как использовать полученное выражение для исследования свойств минимума с помощью гауссовского сэмплирования. Это может быть полезно в изучении sharp и flat минимумов и в анализе связи работы SGD со структурой матрицы Гессе.

3 Постановка задачи

Пусть $\mathcal{L}_k(\mathbf{w})$ – функция потерь модели с параметрами $\mathbf{w} \in \mathbb{R}^N$ на выборке размера k . Минимум функции потерь $\mathbf{w}_k^*$:

$$\mathbf{w}_k^* = \arg \min_{\mathbf{w} \in \mathbb{R}^N} \mathcal{L}_k(\mathbf{w})$$

В предположении, что $\mathcal{L}_k(\mathbf{w})$ дважды непрерывно дифференцируема, верна аппроксимация Тейлора второго порядка

$$\mathcal{L}_k(\mathbf{w}) = \mathcal{L}_k(\mathbf{w}_k^*) + \nabla \mathcal{L}_k(\mathbf{w}_k^*)^T (\mathbf{w} - \mathbf{w}_k^*) + \frac{1}{2} (\mathbf{w} - \mathbf{w}_k^*)^T \mathbf{H}_k (\mathbf{w} - \mathbf{w}_k^*) + o(|\mathbf{w} - \mathbf{w}_k^*|^2)$$

$\mathbf{H}_k = \nabla^2 \mathcal{L}_k(\mathbf{w}_k^*)$ – матрица Гессе функции потерь в точке минимума.

Для исследования ландшафта оптимизационной поверхности используется Monte-Carlo сэмплирование из гауссовского распределения

$$\mathbf{w} \sim \mathcal{N}(\mathbf{w}_k^*, \mathbf{\Sigma}),$$

где матрица $\mathbf{\Sigma}$ отвечает за дисперсию сэмплирования.

Предлагается делать сэмплирование в подпространстве наибольшей кривизны с одинаковой дисперсией σ^2 , то есть в подпространстве d главных собственных векторов $\mathbf{H}_k$. В таком случае $\mathbf{\Sigma}$ в подпространстве наибольшей кривизны будет равна $\sigma^2 \mathbf{I}_d$, где $\mathbf{I}_d$ – единичная матрица размерности d .

Целью работы является выбор такого значения параметра σ , при котором сэмплирование из распределения $\mathcal{N}(\mathbf{w}_k^*, \sigma^2 \mathbf{I}_d)$ будет наиболее точно отражать локальные свойства оптимизационной поверхности в окрестности минимума.

Мы хотим найти параметр σ_k^* , для которого выполнено:

$$\sigma_k^* = \sup(\sigma > 0 : \mathbb{P}(\|\mathbf{w} - \mathbf{w}_k^*\| < R_k) > 1 - \varepsilon),$$

где R_k – характерный радиус шара с центром в $\mathbf{w}_k^*$, для которого корректна аппроксимация Тейлора второго порядка, а ε – требуемая точность.

Теоретическая значимость полученных результатов состоит в том, что предложенный метод может уточнить оценку сходимости оптимизационной поверхности и приблизить решение задач о нахождении оптимального размера обучающей выборки. [3]

4 Метод выбора параметра σ

Для определения значения σ^* будем использовать переход к подпространству наибольшей кривизны. Обозначим за $\mathbf{U}_d = [\mathbf{u}_1, \dots, \mathbf{u}_d]$ матрицу из d главных собственных векторов матрицы $\mathbf{H}$. Тогда подпространство наибольшей кривизны это $\mathcal{Lin}([\mathbf{u}_1, \dots, \mathbf{u}_d])$ и в нём матрица Гессе будет равна $\mathbf{H}_d = \mathbf{U}_d^T \mathbf{H} \mathbf{U}_d = \text{diag}(\lambda_1, \dots, \lambda_d)$, где $\lambda_1, \dots, \lambda_d$ - d наибольших собственных значений $\mathbf{H}$. В таком случае получаем, что у $\mathbf{H}_d$ будут большие положительные собственные значения, что пригодится в дальнейшей оценке параметра σ^* .

5 Теоретический анализ

Здесь и далее считаем, что N и k из постановки зафиксированны, поэтому опустим индексы в обозначении функции потерь и минимума, а также используется 2-норма. В окрестности минимума $\nabla \mathcal{L}(\mathbf{w}^*) = 0$, а значит аппроксимация Тейлора второго порядка принимает следующий вид:

$$\mathcal{L}(\mathbf{w}^* + \mathbf{h}) = \mathcal{L}(\mathbf{w}^*) + \frac{1}{2} \mathbf{h}^T \mathbf{H} \mathbf{h} + \rho(\mathbf{h})$$

Где $\mathbf{h} = \mathbf{w} - \mathbf{w}^*$, $\mathbf{h} \in \mathbb{R}^N$, а ρ - остаточный член.

Мы хотим, чтобы аппроксимация Тейлора второго порядка была корректна в окрестности минимума, то есть остаточный член должен быть мал по сравнению с квадратичной частью.

Теорема 1: В подпространстве наибольшей кривизны для радиуса $R_\psi = \frac{3\psi \lambda_{\min}(\mathbf{H}_d)}{L_{\mathbf{H}}}$ для точек из шара $\mathcal{B}_{R_\psi}(\mathbf{w}^*)$ в 2-норме остаточный член аппроксимации Тейлора второго порядка удовлетворяет неравенству

$$|\rho(\mathbf{h})| \leq \psi \times \frac{1}{2} \|\mathbf{h}^T \mathbf{H}_d \mathbf{h}\|$$

Где $\mathbf{H}_d$ - матрица Гессе в подпространстве наибольшей кривизны, $\lambda_{\min}(\mathbf{H}_d)$ - её минимальное собственное значение, а $L_{\mathbf{H}}$ - константа Липшица для $\mathbf{H}$.

То есть квадратичная часть описывает поведение функции в окрестности минимума с точностью ψ .

Доказательство:

Из аппроксимации Тейлора второго порядка с остаточным членом в интегральной форме известно:

$$\rho(\mathbf{h}) = \int_0^1 (1-t) \mathbf{h}^T (\nabla^2 \mathcal{L}(\mathbf{w}^* + t\mathbf{h}) - \nabla^2 \mathcal{L}(\mathbf{w}^*)) \mathbf{h} dt$$

Предположение: матрице Гессе - липшицева с константой Липшица $L_{\mathbf{H}}$:

$$\|\nabla^2 \mathcal{L}(\mathbf{u}) - \nabla^2 \mathcal{L}(\mathbf{v})\|_2 \leq L_{\mathbf{H}} \|\mathbf{u} - \mathbf{v}\|_2 \quad \forall \mathbf{u}, \mathbf{v} \in \mathcal{B}_r(\mathbf{w}^*)$$

Оценим остаточный член $\rho(\mathbf{H})$:

$$\begin{aligned} |\rho(\mathbf{h})| &= \left| \int_0^1 (1-t) \mathbf{h}^T (\nabla^2 \mathcal{L}(\mathbf{w}^* + t\mathbf{h}) - \nabla^2 \mathcal{L}(\mathbf{w}^*)) \mathbf{h} dt \right| \leq \\ &\leq \int_0^1 \|\mathbf{h}\|^2 (1-t) \|\nabla^2 \mathcal{L}(\mathbf{w}^* + t\mathbf{h}) - \nabla^2 \mathcal{L}(\mathbf{w}^*)\| dt \end{aligned}$$

Используем липшицевость:

$$\int_0^1 \|\mathbf{h}\|^2 (1-t) \|\nabla^2 \mathcal{L}(\mathbf{w}^* + t\mathbf{h}) - \nabla^2 \mathcal{L}(\mathbf{w}^*)\| dt \leq \int_0^1 \|\mathbf{h}\|^2 (1-t) L_{\mathbf{H}} \|t\mathbf{h}\| dt =$$

$$= \int_0^1 \|\mathbf{h}\|^3 L_{\mathbf{H}} t(1-t) dt = \frac{1}{6} L_{\mathbf{H}} \|\mathbf{h}\|^3$$

Итоговая оценка на $\rho(\mathbf{h})$:

$$|\rho(\mathbf{h})| \leq \frac{1}{6} L_{\mathbf{H}} \|\mathbf{h}\|^3$$

Квадратичная аппроксимация будет хорошо приближать функцию в случае, если квадратичный член будет описывать разность $\mathcal{L}(\mathbf{w}^* + \mathbf{h}) - \mathcal{L}(\mathbf{w}^*)$, то есть если $\rho(\mathbf{h})$ будет мало относительно $\frac{1}{2} \mathbf{h}^T \mathbf{H} \mathbf{h}$, или же

$$|\rho(\mathbf{h})| \leq \psi \times \frac{1}{2} \|\mathbf{h}^T \mathbf{H} \mathbf{h}\|$$

для $\psi \in (0, 1)$, который отражает насколько точную мы хотим аппроксимацию.

Получаем

$$|\rho(\mathbf{h})| = \frac{1}{6} L_{\mathbf{H}} \|\mathbf{h}\|^3 \leq \frac{\psi}{2} \|\mathbf{h}^T \mathbf{H} \mathbf{h}\|$$

При переходе к сэмплированию в подпространстве d главных собственных векторов у матрицы Гессе останутся только большие собственные значения.

Далее будем считать, что мы работаем в подпространстве главных собственных векторов.

Матрицу Гессе в новом пространстве будем обозначать $\mathbf{H}_d := \mathbf{U}^T \mathbf{H} \mathbf{U}$, где $\mathbf{U}$ - матрица перехода к подпространству главных собственных векторов.

Пусть минимальное собственное значение матрицы Гессе - $\lambda_{\min}(\mathbf{H}_d)$.

Сэмплирование имеет одинаковую дисперсию по каждой компоненте, поэтому, чтобы оставаться в рамках квадратичной аппроксимации, неравенство на $\rho(\mathbf{H}_d)$ должно выполняться для всех возможных направлений $\mathbf{h}$ в подпространстве главных собственных векторов, в том числе для $\inf_{\|\mathbf{u}\|=\|\mathbf{h}\|} \frac{1}{2} \mathbf{u}^T \mathbf{H}_d \mathbf{u}$, где $\mathbf{u} \in \mathbb{R}^d$.

Оценим выражение $\frac{1}{2} \mathbf{u}^T \mathbf{H}_d \mathbf{u}$.

Для этого разложим $\mathbf{u}$ по главным собственным векторам матрицы Гессе:

$$\mathbf{u} = \sum_{j=1}^d \theta_j \mathbf{e}_j$$

Где $\{\mathbf{e}_j\}_{j=1}^d$ - собственные вектора $\mathbf{H}_d$.

Тогда сделаем оценку:

$$\begin{aligned} \frac{1}{2} \mathbf{u}^T \mathbf{H}_d \mathbf{u} &= \frac{1}{2} \left(\sum_{j=1}^d \theta_j \mathbf{e}_j \right)^T \mathbf{H}_d \left(\sum_{j=1}^d \theta_j \mathbf{e}_j \right) = \frac{1}{2} \left(\sum_{j=1}^d \theta_j \mathbf{e}_j \right)^T \left(\sum_{j=1}^d \theta_j \lambda_j(\mathbf{H}_d) \mathbf{e}_j \right) = \\ &= \sum_{j=1}^d \theta_j^2 \|\mathbf{e}_j\|^2 \lambda_j(\mathbf{H}_d) \geq \frac{1}{2} \lambda_{\min}(\mathbf{H}_d) \sum_{j=1}^d \theta_j^2 \|\mathbf{e}_j\|^2 = \frac{1}{2} \lambda_{\min}(\mathbf{H}_d) \|\mathbf{u}\|^2 = \frac{1}{2} \lambda_{\min}(\mathbf{H}_d) \|\mathbf{h}\|^2 \end{aligned}$$

В переходах было использовано то, что базис ортонормированный, что $\mathbf{H}_d \mathbf{e}_j = \lambda_j \mathbf{e}_j$ и что сумма квадратов коэффициентов разложения θ_j это норма вектора $\mathbf{u}$. То есть, если мы оценим квадратичную часть снизу через $\lambda_{\min}(\mathbf{H}_d)$, то для полученных ρ квадратичная аппроксимация будет тем более работать. Следовательно, оценка для ρ принимает вид:

$$\rho(\mathbf{h}) = \frac{1}{6} L_{\mathbf{H}} \|\mathbf{h}\|^3 \leq \frac{\psi \lambda_{\min}(\mathbf{H}_d)}{2} \|\mathbf{h}\|^2$$

Из чего получаем:

$$\|\mathbf{h}\| \leq \frac{3\psi \lambda_{\min}(\mathbf{H}_d)}{L_{\mathbf{H}}}$$

Получаем, что для радиуса $R_\psi = \frac{3\psi\lambda_{\min}(\mathbf{H}_d)}{L_{\mathbf{H}}}$ точки из шара $\mathcal{B}_{R_\psi}(\mathbf{w}^*)$ в 2-норме будут соответствовать именно локальному ландшафту оптимизационной поверхности, отвечающему минимуму $\mathbf{w}^*$.

Теорема 1 доказана.

Вернёмся к параметру σ^* .

$$\sigma^* = \sup(\sigma > 0 : \mathbb{P}(\|\mathbf{w} - \mathbf{w}^*\| < R) > 1 - \varepsilon),$$

Подставим $R = R_\psi$:

$$\sigma^* = \sup(\sigma > 0 : \mathbb{P}\left(\|\mathbf{w} - \mathbf{w}^*\| < \frac{3\psi\lambda_{\min}(\mathbf{H}_d)}{L_{\mathbf{H}}}\right) > 1 - \varepsilon),$$

Осталось подобрать дисперсию так, чтобы гауссовское сэмплирование попадало в нужный интервал с вероятностью $1 - \varepsilon$.

То есть нужно решить следующую задачу:

Задан радиус $r > 0$.

Для d -мерного гауссовского распределения $\mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_d)$ нужно максимальное σ , для которого хотя бы $(1 - \varepsilon)$ ая часть точек будет попадать в $\mathcal{B}_r(\mathbf{0})$ в 2-норме.

Значит, мы хотим, чтобы для сэмплирования распределения $\mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_d)$ размера S точек $\{\xi_l\}_{l=1}^S \in \mathbb{R}^d$ выполнялось:

$$\mathbb{P}(\xi \in \mathcal{B}_r(\mathbf{0})) > (1 - \varepsilon)$$

Пусть $\xi = \sigma\eta$.

Тогда $\eta \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$. Значит $\|\eta\|^2 = \sum_{i=1}^d \eta_i^2 \sim \chi^2(d)$.

Получаем:

$$\mathbb{P}(\xi \in \mathcal{B}_r(\mathbf{0})) = \mathbb{P}(\|\xi\|^2 < r^2) = \mathbb{P}\left(\|\eta\|^2 < \frac{r^2}{\sigma^2}\right) = 1 - \varepsilon$$

Обозначим $\zeta = \|\eta\|^2 = \sum_{i=1}^d \eta_i^2 \implies \zeta \sim \chi^2(d)$. Следовательно:

$$\mathbb{P}(\xi \in \mathcal{B}_r(\mathbf{0})) = 1 - \varepsilon = \mathbb{P}\left(\zeta < \frac{r^2}{\sigma^2}\right)$$

Значит, в граничном случае, когда достигается супремум, получается:

$$\mathbb{P}\left(\zeta < \frac{r^2}{(\sigma^*)^2}\right) = 1 - \varepsilon$$

Следовательно: $\frac{r^2}{(\sigma^*)^2} = \chi_{1-\varepsilon}^2(d)$, то есть

$$(\sigma^*)^2 = \frac{r^2}{\chi_{1-\varepsilon}^2(d)}$$

Подставим найденное в рамках задачи R_ψ , чтобы получить итоговое выражение для σ^* :

$$\sigma^* = \sqrt{\frac{9\psi^2\lambda_{\min}^2(\mathbf{H}_d)}{L_{\mathbf{H}}^2\chi_{1-\varepsilon}^2(d)}}$$

Список литературы

- [1] Vladimir N. Vapnik. *The Nature of Statistical Learning Theory*. Springer, New York, NY, USA, 1995.
- [2] Meshkov V. C. N. S. Kiselev and A. V. Grabovoy. Robust convergence of loss landscapes through distributional averaging. In *ISP RAS open conference*, 2025.
- [3] N. S. Kiselev and A. V. Grabovoy. Sample size determination: Likelihood bootstrapping. *Computational Mathematics and Mathematical Physics*, 65(2):25–30, 2025.
- [4] N. Kiselev and A. Grabovoy. Sample size determination: Posterior distributions proximity. *Computational Management Science*, 22(1):1, 2025.
- [5] Hao Li, Zheng Xu, Gavin Taylor, Christoph Studer, and Tom Goldstein. Visualizing the loss landscape of neural nets. In *Advances in Neural Information Processing Systems*, 2018.
- [6] Yichu Xu, Xin-Chun Li, Lan Li, and De-Chuan Zhan. Visualizing, rethinking, and mining the loss landscape of deep neural networks. *arXiv preprint*, 2024.
- [7] Levent Sagun, Utku Evci, Vincent Ugur Guney, Yann Dauphin, and Léon Bottou. Empirical analysis of the hessian of over-parametrized neural networks. *arXiv preprint arXiv:1706.04454*, 2017.
- [8] Behrooz Ghorbani, Shankar Krishnan, and Ying Xiao. An investigation into neural net optimization via hessian analysis. *arXiv preprint arXiv:1906.03829*, 2019.
- [9] Yikai Wu, Xingyu Zhu, Chenwei Wu, Annie Wang, and Rong Ge. Dissecting hessian: Understanding common structure of hessian in neural networks. In *International Conference on Learning Representations*, 2021.
- [10] Nicholas P. Baskerville, Diego Granziol, and Jonathan P. Keating. Appearance of random matrix theory in deep learning. *arXiv preprint*, 2021.
- [11] Sidak Pal Singh, Thomas Hofmann, and Bernhard Schölkopf. The hessian perspective into the nature of convolutional neural networks. In *International Conference on Machine Learning (ICML)*, 2023.
- [12] Sepp Hochreiter and Jürgen Schmidhuber. Flat minima. *Neural Computation*, 9(1):1–42, 1997.
- [13] Laurent Dinh, Razvan Pascanu, Samy Bengio, and Yoshua Bengio. Sharp minima can generalize for deep nets. In *International Conference on Machine Learning (ICML)*, 2017.
- [14] Pierre Foret, Ariel Kleiner, Hossein Mobahi, and Behnam Neyshabur. Sharpness-aware minimization for efficiently improving generalization. In *International Conference on Learning Representations (ICLR)*, 2021.
- [15] Nitish Shirish Keskar, Dheevatsa Mudigere, Jorge Nocedal, Mikhail Smelyanskiy, and Ping Tak Peter Tang. On large-batch training for deep learning: Generalization gap and sharp minima. *arXiv preprint arXiv:1609.04836*, 2017.
- [16] Wenjie Zhou, Bohan Wang, Wei Chen, and Xueqi Cheng. Bsfa: Leveraging the subspace dichotomy to accelerate neural network training. *arXiv preprint*, 2025.
- [17] Minhak Song, Kwangjun Ahn, and Chulhee Yun. Does sgd really happen in tiny subspaces? In *International Conference on Learning Representations (ICLR)*, 2025. arXiv:2405.16002.