

Адаптивный выбор параметров распределения сэмплирования для Monte Carlo оценки сходимости оптимизационной поверхности

Еникеев Арнольд и Никита Киселёв

Аннотация

Исследование поведения функции потерь возле минимума является важной задачей для работы нейросетей и для поиска оптимального размера обучающей выборки. Распределенный подход к оценке сходимости поверхности функции потерь использует Monte Carlo сэмплирование из гауссовского распределения в окрестности минимума. Предыдущие исследования показали, что оценка сильно зависит от дисперсии сэмплирования. Целью исследования является разработка адаптивных методов выбора параметров распределения сэмплирования на основе свойств кривизны оптимизационной поверхности и провести сравнительный анализ различных стратегий выбора. В данной работе предлагается метод, использующий свойства матрицы Гессе для более точной оценки сходимости поверхности функции потерь. Различные стратегии выбора сравниваются на задаче классификации изображений. Развитие исследований в этом направлении позволит сделать распределенный подход более практичным и устойчивым. Результаты могут быть полезны для анализа оптимальной обучающей выборки в задаче обучения нейросетей.

1 Введение




Рис. 1: Критерий выбора параметра σ : точки сэмплирования должны попадать в шар характерного радиуса с центром в минимуме $\mathcal{L}(\mathbf{w}^*)$

В статистической теории машинного обучения [1] качество модели напрямую зависит от размера обучающей выборки. Для параметрических моделей функция потерь вычисляется по ограниченному набору данных, поэтому существует важная задача по определению

оптимального размера обучающей выборки. Для этого исследуется сходимость ландшафта функции потерь в зависимости от размера выборки. Когда геометрия ландшафта перестёт значительно меняться при добавлении нового элемента, можно делать выводы о достаточности размера обучающих данных.

В предыдущих исследованиях [2, 3] были предложены критерии оценки сходимости оптимизационной поверхности при увеличении размера выборки, использующие гауссовское сэмплирование в окрестности минимума $\mathcal{L}(\mathbf{w})$. В [Прочитать статью, которая ещё не вышла] вводятся ещё два критерия: Quadratic Monte-Carlo и Gaussian-moment quadratic estimator, которые более эффективны с вычислительной точки зрения, а также доказываются их сходимость.

Однако, для практического использования критериев Quadratic Monte-Carlo и Gaussian-moment quadratic estimator недостаточно теоретической сходимости: необходимо, чтобы точки сэмплирования попадали в область, где ландшафт можно описать квадратичной аппроксимацией Тейлора в окрестности $\mathbf{w}^*$ с высокой точностью. В таком случае данные критерии корректно отражают сходимость оптимизационной поверхности при росте объёма выборки.

Наша задача состоит в том, чтобы найти радиус R такой, что в шаре $\mathcal{B}_R(\mathbf{w}^*)$ функцию потерь можно было достаточно точно описать квадратичной аппроксимацией и предложить метод выбора параметра σ , при котором гауссовское сэмплирование с заданной вероятностью попадает в данный шар. Это позволит эффективно использовать квадратичные критерии на практике. Также необходимо будет проверить корректность предложенного метода выбора параметра σ и исследовать поведение критериев Quadratic Monte-Carlo и Gaussian-moment quadratic estimator при полученном значении σ .

2 Связанные работы

Исследование зависимости ландшафта функции потерь от размера обучающей выборки. Анализ зависимости обучения параметрической модели от размера выборки является важной задачей в классической теории обучения [1]. В недавних исследованиях были предложены критерии оценки сходимости ландшафта функции потерь при увеличении объёма данных [3, 4], в частности, квадратичный критерий Δ_2 и абсолютный критерий Δ_1 , а также показана их сходимость.

В [2] предложена идея делать гауссовское сэмплирование точек по Монте-Карло для оценки сходимости на практике. В статье [Прочитать статью, которая ещё не вышла] предложены критерии Quadratic Monte-Carlo и Gaussian-moment quadratic estimator, которые более эффективны с вычислительной точки зрения, однако их практическая применимость напрямую зависит от того, насколько точно выполняется квадратичная аппроксимация в характерной области для сэмплирования.

В нашей работе мы предлагаем адаптивный метод выбора параметра σ , при котором гарантируется выполнение квадратичной аппроксимации с заданной точностью и проводим вычислительный эксперимент с полученным σ для сходимости данных критериев. В отличие от предыдущих работ, мы получаем точное выражение для параметра σ и показываем его корректность, а не работаем в абстрактной области корректности аппроксимации Тейлора 2 порядка.

Ландшафт функции потерь и его локальная геометрия. Изучению локальной геометрии функции потерь посвящено значительное количество работ, предлагающих теоретический анализ и различные подходы к визуализации ландшафта [5, 6]. В частности, в них были описаны особенности кривизны ландшафта и спектральные свойства матрицы Гессе [7, 8, 9].

Предыдущие исследования показали, что на практике ландшафт функции потерь крайне анизотропен, то есть значительная часть спектра матрицы Гессе имеет околонулевые значения [10, 11]. В недавних исследованиях для практического изучения ландшафта функции

потерь была предложена идея сэмплирования в подпространстве наибольшей кривизны, то есть подпространство d главных собственных векторов матрицы Гессе $\mathbf{H}$ [статья с идеей перехода в подпространство наибольшей кривизны и с доказательством оптимальности среди всех подпространства размера D]. В нашей работе мы развиваем данную идею и предлагаем метод выбора параметра σ для сэмплирования в данном подпространстве и показываем, что при таком выборе σ сэмплирование будет отражать локальные свойства минимума $\mathcal{L}(\mathbf{w})$.

Локальные свойства ландшафта в методах оптимизации. Также ряд работ был посвящён изучению связи геометрии ландшафта функции потерь и структуры матрицы Гессе с работой методов стохастической оптимизации. Для функции потерь параметрических моделей разделяют flat (плоские) и sharp (острые) минимумы по кривизне поверхности в их окрестности[12]. В частности, согласно результатам исследований, в случае flat минимумов параметрическая модель обладает большей обобщающей способностью [13, 14, 15]. Было показано, что стохастические методы, такие как SGD, за счёт недетерминированных обновлений обычно приводят к решениям в более плоских минимумах. В недавних работах было изучено, как ведут себя траектории SGD на всём пространстве параметров и в подпространствах наибольшей кривизны [16, 17]. В методах оптимизации важно понимать, как устроена окрестность минимума и уметь исследовать структуру ландшафта в подпространствах собственных векторов матрицы Гессе, что тесно пересекается с нашей работой. В отличие от других исследований, в нашей работе мы также предлагаем численные оценки для характерного радиуса корректности аппроксимации Тейлора 2 порядка и показываем, как использовать полученное выражение для исследования свойств минимума с помощью гауссовского сэмплирования. Это может быть полезно в изучении sharp и flat минимумов и в анализе связи работы SGD со структурой матрицы Гессе.

3 Постановка задачи

Пусть $\mathcal{L}_k(\mathbf{w})$ – функция потерь модели с параметрами $\mathbf{w} \in \mathbb{R}^N$ на выборке размера k . Минимум функции потерь $\mathbf{w}_k^*$:

$$\mathbf{w}_k^* = \arg \min_{\mathbf{w} \in \mathbb{R}^N} \mathcal{L}_k(\mathbf{w})$$

В предположении, что $\mathcal{L}_k(\mathbf{w})$ дважды непрерывно дифференцируема, верна аппроксимация Тейлора второго порядка

$$\mathcal{L}_k(\mathbf{w}) = \mathcal{L}_k(\mathbf{w}_k^*) + \nabla \mathcal{L}_k(\mathbf{w}_k^*)^T (\mathbf{w} - \mathbf{w}_k^*) + \frac{1}{2} (\mathbf{w} - \mathbf{w}_k^*)^T \mathbf{H}_k (\mathbf{w} - \mathbf{w}_k^*) + o(|\mathbf{w} - \mathbf{w}_k^*|^2)$$

$\mathbf{H}_k = \nabla^2 \mathcal{L}_k(\mathbf{w}_k^*)$ – матрица Гессе функции потерь в точке минимума.

Для исследования ландшафта оптимизационной поверхности используется Monte-Carlo сэмплирование в окрестности минимума $\mathbf{w}_k^*$.

Предлагается делать сэмплирование в подпространстве наибольшей кривизны, то есть подпространстве, образованном d собственными векторами матрицы Гессе, отвечающим её d наибольшим собственным значениям. Обозначим через

$$\mathbf{U}_d = [\mathbf{u}_1, \dots, \mathbf{u}_d] \in \mathbb{R}^{N \times d}$$

матрицу, составленную из этих собственных векторов.

Тогда точки сэмплирования будут выглядеть следующим образом:

$$\begin{aligned} \mathbf{w} &= \mathbf{w}_k^* + \mathbf{U}_d \mathbf{z} \\ \mathbf{z} &\sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_d) \end{aligned}$$

где $\mathbf{I}_d$ — единичная матрица размерности d .

Итак, цель работы - найти такое значение параметра σ^* , при котором сэмплирование

$$\mathbf{w} = \mathbf{w}^* + \mathbf{U}_d \mathbf{z}$$

$$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_d)$$

будет наиболее точно отражать локальные свойства оптимизационной поверхности в окрестности минимума и обеспечивать корректность квадратичной аппроксимации, необходимой для применения критериев Quadratic Monte-Carlo и Gaussian-moment quadratic estimator. Если говорить строго, то мы хотим найти параметр σ_k^* , для которого выполнено:

$$\sigma_k^* = \sup(\sigma > 0 : \mathbb{P}(\|\mathbf{w} - \mathbf{w}_k^*\| < R_k) > 1 - \varepsilon),$$

где R_k — характерный радиус шара с центром в $\mathbf{w}_k^*$, для которого корректна аппроксимация Тейлора второго порядка, а ε — требуемая точность.

Теоретическая значимость полученных результатов состоит в том, что предложенный метод позволит на практике использовать сильные квадратичные критерии для оценки сложности ландшафта функции потерь при увеличении размера выборки, а также может пригодиться в анализе структуры оптимизационной поверхности.

4 Метод выбора параметра σ

Для определения значения σ^* будем использовать переход к подпространству наибольшей кривизны. Обозначим за $\mathbf{U}_d = [\mathbf{u}_1, \dots, \mathbf{u}_d]$ матрицу из d главных собственных векторов матрицы $\mathbf{H}$. Тогда подпространство наибольшей кривизны это $\mathcal{Lin}([\mathbf{u}_1, \dots, \mathbf{u}_d])$ и в нём матрица Гессе будет равна $\mathbf{H}_d = \mathbf{U}_d^T \mathbf{H} \mathbf{U}_d = \text{diag}(\lambda_1, \dots, \lambda_d)$, где $\lambda_1, \dots, \lambda_d$ — d наибольших собственных значений $\mathbf{H}$.

Точки сэмплирования будут иметь следующий вид:

$$\mathbf{w} = \mathbf{w}^* + \mathbf{U}_d \mathbf{z}$$

$$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_d)$$

В таком случае получаем, что у $\mathbf{H}_d$ будут большие положительные собственные значения, что пригодится в дальнейшей оценке параметра σ^* .

5 Теоретический анализ

Здесь и далее считаем, что N и k из постановки зафиксированны, поэтому опустим индексы в обозначении функции потерь и минимума, а также используется 2-норма. В окрестности минимума $\nabla \mathcal{L}(\mathbf{w}^*) = 0$, а значит аппроксимация Тейлора второго порядка принимает следующий вид:

$$\mathcal{L}(\mathbf{w}^* + \mathbf{h}) = \mathcal{L}(\mathbf{w}^*) + \frac{1}{2} \mathbf{h}^T \mathbf{H} \mathbf{h} + \rho(\mathbf{h})$$

Где $\mathbf{h} = \mathbf{w} - \mathbf{w}^*$, $\mathbf{h} \in \mathbb{R}^N$, а ρ — остаточный член.

Мы хотим, чтобы аппроксимация Тейлора второго порядка была корректна в окрестности минимума, то есть остаточный член должен быть мал по сравнению с квадратичной частью.

Лемма 1: В подпространстве наибольшей кривизны для радиуса $R_\psi = \frac{3\psi \lambda_{\min}(\mathbf{H}_d)}{L_{\mathbf{H}}}$ для точек из шара $\mathcal{B}_{R_\psi}(\mathbf{w}^*)$ в 2-норме остаточный член аппроксимации Тейлора второго порядка удовлетворяет неравенству

$$|\rho(\mathbf{h})| \leq \psi \times \frac{1}{2} |\mathbf{h}^T \mathbf{H}_d \mathbf{h}|$$

Где $\mathbf{H}_d$ - матрица Гессе в подпространстве наибольшей кривизны, $\lambda_{\min}(\mathbf{H}_d)$ - её минимальное собственное значение, а $L_{\mathbf{H}}$ - константа Липшица для $\mathbf{H}$.

То есть квадратичная часть описывает поведение функции в окрестности минимума с точностью ψ .

Доказательство:

Из аппроксимации Тейлора второго порядка с остаточным членом в интегральной форме известно:

$$\rho(\mathbf{h}) = \int_0^1 (1-t) \mathbf{h}^T (\nabla^2 \mathcal{L}(\mathbf{w}^* + t\mathbf{h}) - \nabla^2 \mathcal{L}(\mathbf{w}^*)) \mathbf{h} dt$$

Предположение: матрица Гессе - липшицева с константой Липшица $L_{\mathbf{H}}$:

$$\|\nabla^2 \mathcal{L}(\mathbf{u}) - \nabla^2 \mathcal{L}(\mathbf{v})\|_2 \leq L_{\mathbf{H}} \|\mathbf{u} - \mathbf{v}\|_2 \quad \forall \mathbf{u}, \mathbf{v} \in \mathcal{B}_r(\mathbf{w}^*)$$

Оценим остаточный член $\rho(\mathbf{H})$:

$$\begin{aligned} |\rho(\mathbf{h})| &= \left| \int_0^1 (1-t) \mathbf{h}^T (\nabla^2 \mathcal{L}(\mathbf{w}^* + t\mathbf{h}) - \nabla^2 \mathcal{L}(\mathbf{w}^*)) \mathbf{h} dt \right| \leq \\ &\leq \int_0^1 \|\mathbf{h}\|^2 (1-t) \|\nabla^2 \mathcal{L}(\mathbf{w}^* + t\mathbf{h}) - \nabla^2 \mathcal{L}(\mathbf{w}^*)\| dt \end{aligned}$$

Используем липшицевость:

$$\begin{aligned} \int_0^1 \|\mathbf{h}\|^2 (1-t) \|\nabla^2 \mathcal{L}(\mathbf{w}^* + t\mathbf{h}) - \nabla^2 \mathcal{L}(\mathbf{w}^*)\| dt &\leq \int_0^1 \|\mathbf{h}\|^2 (1-t) L_{\mathbf{H}} \|t\mathbf{h}\| dt = \\ &= \int_0^1 \|\mathbf{h}\|^3 L_{\mathbf{H}} t(1-t) dt = \frac{1}{6} L_{\mathbf{H}} \|\mathbf{h}\|^3 \end{aligned}$$

Итоговая оценка на $\rho(\mathbf{h})$:

$$|\rho(\mathbf{h})| \leq \frac{1}{6} L_{\mathbf{H}} \|\mathbf{h}\|^3$$

Аппроксимация Тейлора 2 порядка будет хорошо приближать функцию в случае, если квадратичный член будет описывать разность $\mathcal{L}(\mathbf{w}^* + \mathbf{h}) - \mathcal{L}(\mathbf{w}^*)$, то есть если $\rho(\mathbf{h})$ будет мало относительно $\frac{1}{2} \mathbf{h}^T \mathbf{H} \mathbf{h}$, или же

$$|\rho(\mathbf{h})| \leq \psi \times \frac{1}{2} |\mathbf{h}^T \mathbf{H} \mathbf{h}|$$

для $\psi > 0$, который отражает насколько точную мы хотим аппроксимацию.

Получаем

$$|\rho(\mathbf{h})| = \frac{1}{6} L_{\mathbf{H}} \|\mathbf{h}\|^3 \leq \frac{\psi}{2} |\mathbf{h}^T \mathbf{H} \mathbf{h}|$$

При переходе к сэмплированию в подпространстве d главных собственных векторов у матрицы Гессе останутся только большие собственные значения.

Далее будем считать, что мы работаем в подпространстве главных собственных векторов.

Матрицу Гессе в новом пространстве будем обозначать $\mathbf{H}_d := \mathbf{U}^T \mathbf{H} \mathbf{U}$, где $\mathbf{U}$ - матрица перехода к подпространству главных собственных векторов.

Тогда в этом подпространстве оценка на $\rho(\mathbf{h})$ будет выглядеть следующим образом:

$$|\rho(\mathbf{h})| = \frac{1}{6} L_{\mathbf{H}_d} \|\mathbf{h}\|^3 \leq \frac{\psi}{2} |\mathbf{h}^T \mathbf{H}_d \mathbf{h}|$$

Пусть минимальное собственное значение матрицы Гессе - $\lambda_{\min}(\mathbf{H}_d)$.

Сэмплирование имеет одинаковую дисперсию по каждой компоненте, поэтому, чтобы оставаться в рамках квадратичной аппроксимации, неравенство на $\rho(\mathbf{h})$ должно выполняться

для всех возможных направлений $\mathbf{h}$ в подпространстве главных собственных векторов, в том числе для $\inf_{\|\mathbf{u}\|=\|\mathbf{h}\|} \frac{1}{2} \mathbf{u}^T \mathbf{H}_d \mathbf{u}$, где $\mathbf{u} \in \mathbb{R}^d$.

Оценим выражение $\frac{1}{2} \mathbf{u}^T \mathbf{H}_d \mathbf{u}$.

Для этого разложим $\mathbf{u}$ по главным собственным векторам матрицы Гессе:

$$\mathbf{u} = \sum_{j=1}^d \theta_j \mathbf{e}_j$$

Где $\{\mathbf{e}_j\}_{j=1}^d$ - собственные вектора $\mathbf{H}_d$.

Тогда сделаем оценку:

$$\begin{aligned} \frac{1}{2} \mathbf{u}^T \mathbf{H}_d \mathbf{u} &= \frac{1}{2} \left(\sum_{j=1}^d \theta_j \mathbf{e}_j \right)^T \mathbf{H}_d \left(\sum_{j=1}^d \theta_j \mathbf{e}_j \right) = \frac{1}{2} \left(\sum_{j=1}^d \theta_j \mathbf{e}_j \right)^T \left(\sum_{j=1}^d \theta_j \lambda_j(\mathbf{H}_d) \mathbf{e}_j \right) = \\ &= \sum_{j=1}^d \theta_j^2 \|\mathbf{e}_j\|^2 \lambda_j(\mathbf{H}_d) \geq \frac{1}{2} \lambda_{\min}(\mathbf{H}_d) \sum_{j=1}^d \theta_j^2 \|\mathbf{e}_j\|^2 = \frac{1}{2} \lambda_{\min}(\mathbf{H}_d) \|\mathbf{u}\|^2 = \frac{1}{2} \lambda_{\min}(\mathbf{H}_d) \|\mathbf{h}\|^2 \end{aligned}$$

В переходах было использовано то, что базис ортонормированный, что $\mathbf{H}_d \mathbf{e}_j = \lambda_j \mathbf{e}_j$ и что сумма квадратов коэффициентов разложения θ_j это норма вектора $\mathbf{u}$. То есть, если мы оценим квадратичную часть снизу через $\lambda_{\min}(\mathbf{H}_d)$, то для полученных ρ квадратичная аппроксимация будет тем более работать. Следовательно, оценка для ρ принимает вид:

$$\rho(\mathbf{h}) = \frac{1}{6} L_{\mathbf{H}_d} \|\mathbf{h}\|^3 \leq \frac{\psi \lambda_{\min}(\mathbf{H}_d)}{2} \|\mathbf{h}\|^2$$

Из чего получаем:

$$\|\mathbf{h}\| \leq \frac{3\psi \lambda_{\min}(\mathbf{H}_d)}{L_{\mathbf{H}_d}}$$

Получаем, что для радиуса $R_\psi = \frac{3\psi \lambda_{\min}(\mathbf{H}_d)}{L_{\mathbf{H}_d}}$ точки из шара $\mathcal{B}_{R_\psi}(\mathbf{w}^*)$ в 2-норме будут соответствовать именно части ландшафта оптимизационной поверхности, в которой корректна аппроксимация Тейлора 2 порядка.

Лемма 1 доказана.

Вернёмся к параметру σ^* .

Теорема 1: Пусть в подпространстве d главных собственных векторов матрицы Гессе осуществляется сэмплирование:

$$\begin{aligned} \mathbf{w} &= \mathbf{w}^* + \mathbf{U}_d \mathbf{z} \\ \mathbf{z} &\sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_d) \end{aligned}$$

Характерный радиус области корректности квадратичной аппроксимации равен

$$R_\psi = \frac{3\psi \lambda_{\min}(\mathbf{H}_d)}{L_{\mathbf{H}_d}}.$$

Тогда максимальное значение параметра σ^* , при котором гауссовское сэмплирование попадает в $\mathcal{B}_{R_\psi}(\mathbf{w}^*)$ с вероятностью не менее $1 - \varepsilon$, задаётся формулой

$$\sigma^* = \sqrt{\frac{9\psi^2 \lambda_{\min}^2(\mathbf{H}_d)}{L_{\mathbf{H}_d}^2 \chi_{1-\varepsilon}^2(d)}}$$

Доказательство:

Рассмотрим формулу для σ^* :

$$\sigma^* = \sup(\sigma > 0 : \mathbb{P}(\|\mathbf{w} - \mathbf{w}^*\| < R) > 1 - \varepsilon),$$

Подставим $R = R_\psi$:

$$\sigma^* = \sup(\sigma > 0 : \mathbb{P}\left(\|\mathbf{w} - \mathbf{w}^*\| < \frac{3\psi\lambda_{\min}(\mathbf{H}_d)}{L_{\mathbf{H}_d}}\right) > 1 - \varepsilon),$$

Осталось подобрать дисперсию так, чтобы гауссовское сэмплирование попадало в нужный интервал с вероятностью $1 - \varepsilon$.

То есть нужно решить следующую задачу:

Задан радиус $r > 0$.

Для d -мерного гауссовского распределения $\mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_d)$ нужно максимальное σ , для которого хотя бы $(1 - \varepsilon)$ ая часть точек будет попадать в $\mathcal{B}_r(\mathbf{0})$ в 2-норме.

Значит, мы хотим, чтобы для сэмплирования распределения $\mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_d)$ размера S точек $\{\xi_l\}_{l=1}^S \in \mathbb{R}^d$ выполнялось:

$$\mathbb{P}(\xi \in \mathcal{B}_r(\mathbf{0})) > (1 - \varepsilon)$$

Пусть $\xi = \sigma\eta$.

Тогда $\eta \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$. Значит $\|\eta\|^2 = \sum_{i=1}^d \eta_i^2 \sim \chi^2(d)$.

Получаем:

$$\mathbb{P}(\xi \in \mathcal{B}_r(\mathbf{0})) = \mathbb{P}(\|\xi\|^2 < r^2) = \mathbb{P}\left(\|\eta\|^2 < \frac{r^2}{\sigma^2}\right) > 1 - \varepsilon$$

Обозначим $\zeta = \|\eta\|^2 = \sum_{i=1}^d \eta_i^2 \implies \zeta \sim \chi^2(d)$. Следовательно:

$$\mathbb{P}(\xi \in \mathcal{B}_r(\mathbf{0})) = \mathbb{P}\left(\zeta < \frac{r^2}{\sigma^2}\right) > 1 - \varepsilon$$

Значит, в граничном случае, когда достигается супремум, получается:

$$\mathbb{P}\left(\zeta < \frac{r^2}{(\sigma^*)^2}\right) = 1 - \varepsilon$$

Следовательно: $\frac{r^2}{(\sigma^*)^2} = \chi_{1-\varepsilon}^2(d)$, то есть

$$(\sigma^*)^2 = \frac{r^2}{\chi_{1-\varepsilon}^2(d)}$$

Подставим найденное в рамках задачи R_ψ , чтобы получить итоговое выражение для σ^* :

$$\sigma^* = \sqrt{\frac{9\psi^2\lambda_{\min}^2(\mathbf{H}_d)}{L_{\mathbf{H}_d}^2\chi_{1-\varepsilon}^2(d)}}$$

Теорема 1 доказана.

Замечание 1: На практике константа Липшица $L_{\mathbf{H}_d}$ не может быть точно вычислена для параметрических моделей из-за большой размерности пространства параметров. Поэтому полученные выражения для R_ψ и σ^* на практике могут быть вычислены лишь приближённо.

В вычислительных экспериментах мы используем для константы Липшица следующую оценку: $L_{\mathbf{H}_d}$ оценивается через $\frac{\|\mathbf{H}_d(t\mathbf{v}) - \mathbf{H}_d(\mathbf{0})\|}{t}$ при малых $t > 0$, для D случайных направлений $\mathbf{v}$ в подпространстве наибольшей кривизны.

Замечание 2: Из полученного выражения видно, что выбор размерности подпространства d существенно влияет на значение σ^* . При увеличении d растёт и квантиль $\chi_{1-\varepsilon}^2(d)$, а значит уменьшается σ^* . В то же время уменьшается $\lambda_{\min}(\mathbf{H}_d)$, что также приводит к уменьшению σ^* . Как было показано в предыдущих исследованиях, пространство параметров крайне анизотропно, поэтому важно уметь правильно подбирать d , чтобы подпространство наибольшей кривизны хорошо приближало исходное, но в то же время не брать достаточно большое d , при котором $\lambda_{\min}(\mathbf{H}_d)$ будет мало.

6 Вычислительный эксперимент

Список литературы

- [1] Vladimir N. Vapnik. *The Nature of Statistical Learning Theory*. Springer, New York, NY, USA, 1995.
- [2] Meshkov V. C. N. S. Kiselev and A. V. Grabovoy. Robust convergence of loss landscapes through distributional averaging. In *ISP RAS open conference*, 2025.
- [3] N. S. Kiselev and A. V. Grabovoy. Sample size determination: Likelihood bootstrapping. *Computational Mathematics and Mathematical Physics*, 65(2):25–30, 2025.
- [4] N. Kiselev and A. Grabovoy. Sample size determination: Posterior distributions proximity. *Computational Management Science*, 22(1):1, 2025.
- [5] Hao Li, Zheng Xu, Gavin Taylor, Christoph Studer, and Tom Goldstein. Visualizing the loss landscape of neural nets. In *Advances in Neural Information Processing Systems*, 2018.
- [6] Yichu Xu, Xin-Chun Li, Lan Li, and De-Chuan Zhan. Visualizing, rethinking, and mining the loss landscape of deep neural networks. *arXiv preprint*, 2024.
- [7] Levent Sagun, Utku Evci, Vincent Ugur Guney, Yann Dauphin, and Léon Bottou. Empirical analysis of the hessian of over-parametrized neural networks. *arXiv preprint arXiv:1706.04454*, 2017.
- [8] Behrooz Ghorbani, Shankar Krishnan, and Ying Xiao. An investigation into neural net optimization via hessian analysis. *arXiv preprint arXiv:1906.03829*, 2019.
- [9] Yikai Wu, Xingyu Zhu, Chenwei Wu, Annie Wang, and Rong Ge. Dissecting hessian: Understanding common structure of hessian in neural networks. In *International Conference on Learning Representations*, 2021.
- [10] Nicholas P. Baskerville, Diego Granziol, and Jonathan P. Keating. Appearance of random matrix theory in deep learning. *arXiv preprint*, 2021.
- [11] Sidak Pal Singh, Thomas Hofmann, and Bernhard Schölkopf. The hessian perspective into the nature of convolutional neural networks. In *International Conference on Machine Learning (ICML)*, 2023.
- [12] Sepp Hochreiter and Jürgen Schmidhuber. Flat minima. *Neural Computation*, 9(1):1–42, 1997.
- [13] Laurent Dinh, Razvan Pascanu, Samy Bengio, and Yoshua Bengio. Sharp minima can generalize for deep nets. In *International Conference on Machine Learning (ICML)*, 2017.
- [14] Pierre Foret, Ariel Kleiner, Hossein Mobahi, and Behnam Neyshabur. Sharpness-aware minimization for efficiently improving generalization. In *International Conference on Learning Representations (ICLR)*, 2021.
- [15] Nitish Shirish Keskar, Dheevatsa Mudigere, Jorge Nocedal, Mikhail Smelyanskiy, and Ping Tak Peter Tang. On large-batch training for deep learning: Generalization gap and sharp minima. *arXiv preprint arXiv:1609.04836*, 2017.
- [16] Wenjie Zhou, Bohan Wang, Wei Chen, and Xueqi Cheng. Bsfa: Leveraging the subspace dichotomy to accelerate neural network training. *arXiv preprint*, 2025.
- [17] Minhak Song, Kwangjun Ahn, and Chulhee Yun. Does sgd really happen in tiny subspaces? In *International Conference on Learning Representations (ICLR)*, 2025. arXiv:2405.16002.